Réseaux de neurones
(2 couches, 1 couche cachée)

Classification binaire

$y \sim \mathcal{B}(p)$ on a $\begin{cases} P(Y=1)=p \\ P(Y=0)=1-p \end{cases}$

on cherche Θ qui maximise la Log Likelihood $\max \log P(Y|x)$

$\Leftrightarrow$ minimiser la BCE

$\Leftrightarrow$ minimiser le coût global.

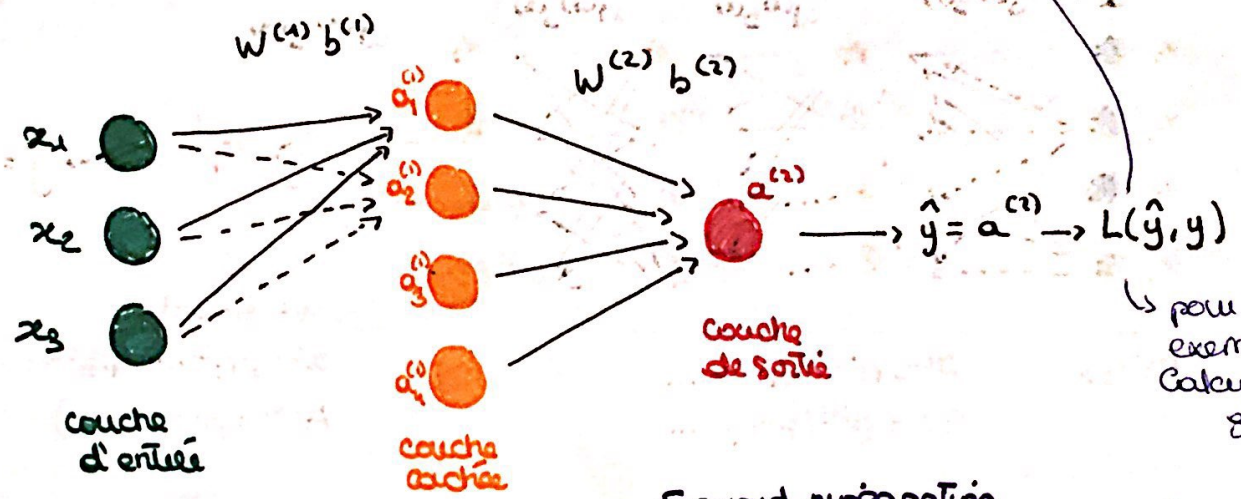

↳ pour tous les exemples on calcule le coût global.

Forward propagation →

$A^{(0)} = X$

$Z^{(1)} = A^{(0)} W^{(1)} + b^{(1)}$

$A^{(1)} = g^{(1)}(Z^{(1)})$

$Z^{(2)} = A^{(1)} W^{(2)} + b^{(2)}$

$A^{(2)} = g^{(2)}(Z^{(2)})$

$\hat{y} = A^{(2)}$

Pour tous les exemples.

Backward propagation ←

$dZ^{(1)} = dA^{(1)} \odot g^{(1)\prime}(Z^{(1)})$

$dW^{(1)} = \frac{1}{m} A^{(0)T} dZ^{(1)}$

$db^{(1)} = \frac{1}{m} \sum_{i=1}^{m} dZ^{(1)}$

$dZ^{(2)} = A^{(2)} - Y$

$dW^{(2)} = \frac{1}{m} A^{(1)T} dZ^{(2)}$

$db^{(2)} = \frac{1}{m} \sum_{i=1}^{m} dZ^{(2)}$

$\boxed{dA^{(1)}} = dZ^{(2)} W^{(2)T}$

Update

$W^{(1)} = W^{(1)} - \alpha dW^{(1)}$

$b^{(1)} = b^{(1)} - \alpha db^{(1)}$

$W^{(2)} = W^{(2)} - \alpha dW^{(2)}$

$b^{(2)} = b^{(2)} - \alpha db^{(2)}$

Réseaux de neurones profonds (plus de 2 couches cachées)

Différents types d'entrainement

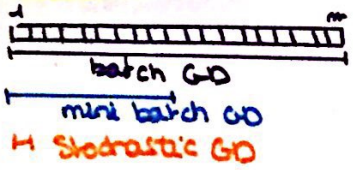

Différents types de descentes de gdt

- mini batch GD
- Momentum
- NAG
- AdaGrad
- AdaDelta
- Adam
- learning rate.

Fonctions d'activation $a = g(z)$ Sortie.

- Sigmoïde (binaire)
- Softmax (multiclasse)

Fonctions d'activation couches => non linéaire

- Sigmoïde
- Tangente hyperbolique } Vanishing gradient.
- ReLU + variantes

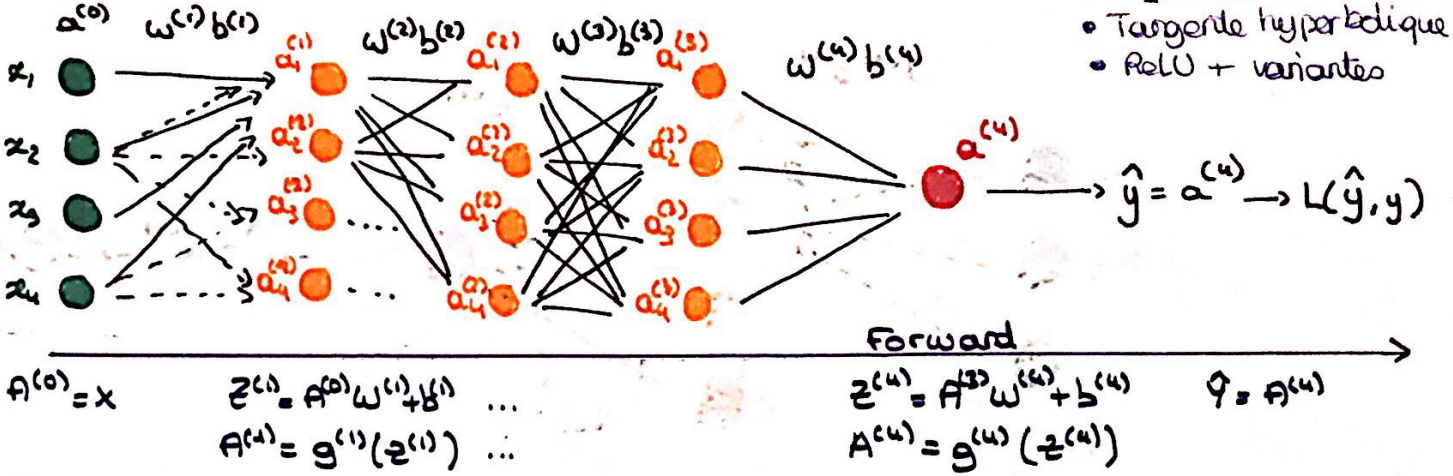

Pour chaque couche, on met en cache certains éléments pour la backpropagation.

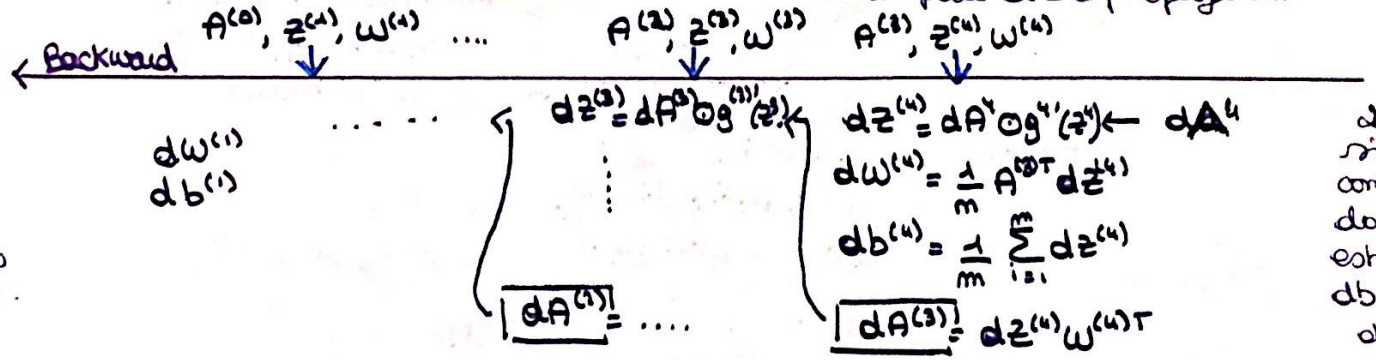

La back propagation est un algorithme efficace qui permet de calculer les dérivées en chaîne des composées en stockant les résultats intermédiaires.

La dérivée de la sigmoïde est comprise entre 0 et $\frac{1}{4}$ donc plus le réseau est profond, plus db ou dw est petit et disparait.

Update $w^{(1)} = w^{(1)} - \alpha dw^{(1)}$ ...
$b^{(1)} = b^{(1)} - \alpha db^{(1)}$

Initialisation des poids

He init = $random(size\,\ell, size\,\ell-1) \times \sqrt{\frac{2}{size\,\ell-1}}$

Xavier = = $\times \sqrt{\frac{1}{size\,\ell-1}}$

Bengio = = $\times \sqrt{\frac{2}{size\,\ell-1 \times size\,\ell}}$

Normalisation = on peut normaliser les entrées par le min et max pour avoir des valeurs similaires de poids, éviter l'explosion des activations et l'instabilité numérique.

Dropout = on enlève aléatoirement certains neurones ce qui retire des connections.
=> joue le rôle de régularisation

Régularisation du réseau réduit l'overfitting.